

TP2

2.2 Give the expression of the gradient f at some point x 2 RN . Create a function which gives as an output the gradient of f at some input vector x.

Rappelons la formule de f :

$$f(x) = \|Hx - y\|_2^2 + \lambda r(x)$$

On va maintenant trouver une formule donnant le gradient de f :

On écrit : $G = \begin{pmatrix} L_1 \\ L_2 \\ \vdots \\ L_n \end{pmatrix}$

Le terme de régularisation $r(x)$ est défini comme :

$$r(x) = \sum_{n=1}^N \sqrt{1 + \left(\frac{[Gx]^{(n)}}{\delta} \right)^2} = \sum_{n=1}^N \sqrt{1 + \left(\frac{L_n x}{\delta} \right)^2}$$

Comme le gradient est linéaire, calculons le gradient de chaque terme :

$$\nabla_x \sqrt{1 + \left(\frac{L_n x}{\delta} \right)^2} = \frac{2L_n^T L_n x}{\delta^2} \frac{1}{2\sqrt{1 + \left(\frac{L_n x}{\delta} \right)^2}} = \frac{L_n^T L_n x}{\delta^2 \sqrt{1 + \left(\frac{L_n x}{\delta} \right)^2}}$$

Le gradient de $r(x)$ par rapport à x est alors :

$$\nabla_x r(x) = \sum_{n=1}^N \frac{L_n^T L_n x}{\delta^2 \sqrt{1 + \left(\frac{L_n x}{\delta} \right)^2}}$$

Avec une identification basique, on obtient :

$$\nabla_x r(x) = G^T \left(\frac{Gx}{\delta^2 \sqrt{1 + \left(\frac{Gx}{\delta} \right)^2}} \right)$$

où la division est effectuée élément par élément (produit d'Hadamard).

Putting it all together, we finally get :

$$\nabla_x f(x) = H^T(Hx - y) + \lambda G^T \left(\frac{Gx}{\delta^2 \sqrt{1 + \left(\frac{Gx}{\delta} \right)^2}} \right)$$

2.3 Show that a Lipschitz constant of f is

Trouvons la constante de lipschitz :

$$\|\nabla f(x) - \nabla f(x')\| \leq \|H^T H(x - x')\| + \|\lambda G^T \left(\frac{Gx}{\delta^2 \sqrt{1 + \left(\frac{Gx}{\delta} \right)^2}} - \frac{Gx'}{\delta^2 \sqrt{1 + \left(\frac{Gx'}{\delta} \right)^2}} \right)\|$$

En utilisant la propriété de sous algèbre de la norme d'opérateur :

$$\|H^T H(x - x')\| \leq \|H^T\| \|H\| \|x - x'\| = \|H\|^2 \|x - x'\|$$

$$\left\| \lambda G^T \left(\frac{Gx}{\delta^2 \sqrt{1 + \left(\frac{Gx}{\delta}\right)^2}} - \frac{Gx'}{\delta^2 \sqrt{1 + \left(\frac{Gx'}{\delta}\right)^2}} \right) \right\| \leq \frac{\lambda}{\delta^2} \|G^T\| \times \left\| \frac{Gx}{\sqrt{1 + \left(\frac{Gx}{\delta}\right)^2}} - \frac{Gx'}{\sqrt{1 + \left(\frac{Gx'}{\delta}\right)^2}} \right\|$$

On pose

$$i(x) = \frac{x}{\sqrt{1 + \left(\frac{x}{\delta}\right)^2}}$$

. C'est une fonction dérivable sur R_*^+ de dérivée

$$i'(x) = \frac{\delta^2}{(\delta^2 + x)^{3/2}}.$$

Elle est maximal en $x = 0$ et vaut $i'(0) = \frac{1}{\delta}$. Par le théorème des inégalités des accroissement finis(appliqué en $x = Gx$ et $y = Gx'$ On obtient :

$$\left\| \frac{Gx}{\sqrt{1 + \left(\frac{Gx}{\delta}\right)^2}} - \frac{Gx'}{\sqrt{1 + \left(\frac{Gx'}{\delta}\right)^2}} \right\| = \|i(Gx) - i(Gx')\| \leq \|G(x - x')\| \times \frac{1}{\delta} = \frac{\|G\|}{\delta} \|(x - x')\|$$

(1)

Ainsi, comme $\|G^T\| = \|G\|$, on peut conclure :

$$\boxed{\|\nabla f(x) - \nabla f(x')\| \leq \|x - x'\| \left(\|H\|^2 + \frac{\lambda \|G\|^2}{\delta^2} \right)}$$

Le gradient est bien lipschitzien de constante $L = \|H\|^2 + \frac{\lambda \|G\|^2}{\delta^2}$

3.2.1 Construct, for all x 2 RN , a quadratic majorant function of f at x. Create a function which gives, as an output, the curvature A(x) of the majorant function at an input vector x.

Appliquons la techniques de majoration des fonctions dérivables paires à ψ :

$$\forall u \in \mathbb{R}, \quad \psi(u) = \sqrt{1 + \frac{u^2}{\delta^2}}$$

ψ est bien paire, maintenant vérifions les 4 propositions :

1. ψ est bien dérivable sur $\mathbb{R}^{+*}$ comme composition de fonctions dérivable sur $\mathbb{R}^{+*}$. Elle est même $C^\infty(\mathbb{R})$
2. Soit $u \in \mathbb{R}^{+*}$, $\psi(\sqrt{u}) = \sqrt{1 + \frac{u}{\delta^2}}$, la fonction $\psi \circ \sqrt{\cdot}$ est $C^\infty(\mathbb{R}^{+*})$ comme composition de fonctions $C^\infty(\mathbb{R}^{+*})$. Montrons qu'elle est concave :

$$(\psi \circ \sqrt{\cdot})'(u) = \frac{1}{2\delta^2} \left(1 + \frac{u}{\delta^2}\right)^{-\frac{1}{2}}$$

$$(\psi \circ \sqrt{\cdot})^{(2)}(u) = -\frac{1}{4\delta^4} \left(1 + \frac{u}{\delta^2}\right)^{-\frac{3}{2}}$$

Comme la dérivée seconde est toujours négative sur $\mathbb{R}^{+*}$, $\psi \circ \sqrt{\cdot}$ est bien concave sur $\mathbb{R}^{+*}$.

3. Calculons la dérivée de ψ pour $u \in \mathbb{R}^{+*}$:

$$\psi'(u) = \frac{u}{\delta^2 \sqrt{1 + \frac{u^2}{\delta^2}}}$$

$\psi'(u)$ est bien positive.

4. On pose $\omega := \frac{\psi'}{Id} : u \in \mathbb{R} \mapsto \frac{1}{\delta^2 \sqrt{1 + \frac{u^2}{\delta^2}}}$

On a $\omega(u) \xrightarrow{u \rightarrow 0} \frac{1}{\delta^2}$.

On a donc la majoration suivante :

$$\forall x, x' \in \mathbb{R}, \quad \boxed{\psi(x) \leq \psi(x') + \psi'(x')(x - x') + \frac{1}{2}\omega(x')(x - x')^2}$$

On applique cette inégalité pour tout $n \in \llbracket 1, 2N \rrbracket$ pour $x = [Gx]^{(n)}$ et $x' = [Gx']^{(n)}$

On obtient :

$$\boxed{r(x) \leq r(x') + \sum_{n=1}^{2N} \frac{[Gx']^n}{\sqrt{1 + (\frac{[Gx']^n}{\delta})^2}} ([Gx]^n - [Gx']^n) + \sum_{n=1}^{2N} \frac{1}{2} \omega([Gx']^n) ([Gx]^n - [Gx']^n)^2}$$

On remarque alors que pour le gradient, il manque G^T . Comme on a en face de nous des scalaires: $[Gx']^n [Gx]^n = L_n x' L_n x = x'^T L_n^T L_n x = \langle L_n^T L_n x', x \rangle$. Donc, en prenant en compte la somme, le terme linéaire est bien sous la forme canonique, i.e c'est le gradient de r calculé plus haut.

En réalisant le même genre de manipulation pour le deuxième terme :

$$\begin{aligned} \omega([Gx']^n) ([Gx]^n - [Gx']^n)^2 &= ([Gx]^n - [Gx']^n) \omega([Gx']^n) ([Gx]^n - [Gx']^n) \\ &= (x - x')^T L_n^T \omega([Gx']^n) L_n (x - x') \\ &= \langle x - x', L_n^T \omega([Gx']^n) L_n (x - x') \rangle \end{aligned}$$

on a donc une forme quadratique $A_r(x') := \sum_{n=1}^{2N} L_n^T \omega([Gx']^n) L_n = G^T \text{Diag}((\omega([Gx']^n)_{n \in \llbracket 1, 2N \rrbracket})) G$.

$$\boxed{A_r(x') = G^T \text{Diag}((\omega([Gx']^n)_{n \in \llbracket 1, 2N \rrbracket})) G}$$

Montrons qu'elle est semi-définie positive :

soit $x', x \in \mathbb{R}^n$,

$$\begin{aligned} \langle A_r(x') x, x \rangle &= \sum_{n=1}^{2N} \langle L_n^T \omega([Gx']^n) L_n x, x \rangle \\ &= \sum_{n=1}^{2N} x^T L_n^T \omega([Gx']^n) L_n x \\ &= \sum_{n=1}^{2N} ([Gx]^n) \omega([Gx']^n) ([Gx]^n) \\ &= \sum_{n=1}^{2N} \omega([Gx']^n) ([Gx]^n)^2. \end{aligned}$$

Or la fonction ω est positive, ainsi :

$$\langle A_r(x')x, x \rangle \geq 0$$

$A_r(x')$ est donc bien semi-définie positive pour tout $x' \in \mathbb{R}^N$.

Dans le cas de notre problème, nos matrices x que l'on cherche sont bornées par une constante α . Ainsi, par définition du gradient, Gx sont bornées par 2α .

$$\text{On a donc } \forall x \in [-\alpha, \alpha]^N \text{ et } n \in \llbracket 1, N \rrbracket, \frac{1}{\delta^2 \sqrt{1 + \frac{(2\alpha)^2}{\delta^2}}} \leq \omega([Gx^n]) \leq \frac{1}{\delta^2}$$

$$\text{On a donc } \frac{2N}{\delta^2 \sqrt{1 + 4 \frac{\alpha^2}{\delta^2}}} \langle G^T Gx, x \rangle \leq \langle A_r(x')x, x \rangle \leq \frac{2N}{\delta^2} \langle G^T Gx, x \rangle$$

Il ne nous reste plus qu'à montrer que $G^T G$ n'admet pas 0 comme valeur propre :

Soit $x \in \mathbb{R}^n$ tel que $\langle G^T Gx, x \rangle = 0$, on a $\|Gx\|^2 = 0$ Donc $Gx = 0$ ie $x = 0$ (si le gradient horizontal et vertical est nulle alors l'image est nulle).

On en déduit donc que $A_r(x')$ est un opérateur autoadjoint positif qui à des valeurs propres minorée par $\min \lambda_G \frac{2N}{\delta^2 \sqrt{1 + 4 \frac{\alpha^2}{\delta^2}}}$ et majorée par $\max \lambda_G \frac{2N}{\delta^2}$ où $\min \lambda_G$ et $\max \lambda_G$ correspondent à la plus petite

et plus grande valeur propre de $G^T G$.

Avant de conclure, on rappelle une majoration du terme l^2 avec sa Hessienne :

$$\|Hx - y\|_2^2 \leq \|Hx' - y\|_2^2 + \langle H^T(Hx' - y), x - x' \rangle + \frac{1}{2} \langle x - x', H^T H(x - x') \rangle$$

On peut enfin donner la forme complète de la fonction majorante en ajoutant le terme quadratique :

$$f(x) = \|Hx - y\|_2^2 + \lambda r(x) \leq f(x') + \langle \nabla f(x'), x - x' \rangle + \langle x - x', (H^T H + \lambda A_r(x'))(x - x') \rangle$$

$$\text{On pose } A(x') := H^T H + \lambda A_r(x'), \text{ on a } \min \lambda_G \frac{2N\lambda}{\delta^2 \sqrt{1 + 4 \frac{\alpha^2}{\delta^2}}} \text{Id} \prec A \prec (\max \lambda_G \frac{2N\lambda}{\delta^2} + \max \lambda_H) \text{Id}$$

Ainsi, A est fortement positive et autoadjointe, la fonction de droite est majorante de f . Ainsi, d'après la slide 17/40 du cours sur les algorithmes MM, l'algorithme converge pour $\theta \in]0, 2[$.

3.2.2 Deduce a MM Quadratic algorithm

On avait prouvé dans les résultats précédent que A était symétrique définie positive. Dans ce cas , L'algorithme MM quadratique est défini comme suit pour une fonction f différentiable :

Algorithm 1 MM Quadratic Algorithm

- 1: **Initialization:** Choisir un point initial x_0 et $\theta \in (0, 2)^{\mathbb{N}}$
 - 2: **while** le critère de convergence n'est pas satisfait **do**
 - 3: Calculer $\nabla f(x_n)$
 - 4: Calculer $A(x_n)$ une forme quadratique majorante de la Hessienne
 - 5: Mettre à jour $x_{n+1} = x_n - \theta_n A(x_n)^{-1} \nabla f(x_n)$
 - 6: **end while**
 - 7: **Return:** x_{final}
-

avec

$$\nabla f(x) = H^T(Hx - y) + \lambda G^T \left(\frac{Gx}{\delta^2 \sqrt{1 + \left(\frac{Gx}{\delta}\right)^2}} \right)$$

$$A(x) := H^T H + \lambda G^T \text{Diag}((\omega([Gx']^n)_{n \in \llbracket 1, 2N \rrbracket})G$$

3.5.1 Prove that, for every $A(x)B(x)$ where $\mathbf{A}$ was defined before

$$A(x) = H^T H + \lambda G^T \text{Diag} \left(\frac{\psi'(Gx)}{Gx} \right) G$$

est symétrique car $H^T H$ et $G^T(\cdot)G$ sont symétriques.

$B(x)$ est diagonale de coefficients :

$$b_i(x) = \mathcal{H}_i^T \mathbf{1} + \lambda \mathcal{G}_i^T \left(\frac{\psi'(Gx)}{Gx} \right),$$

avec :

$$\mathcal{H}_i^{(m)} = |H^{(m,i)}| \sum_{p=1}^N |H^{(m,p)}|, \quad \mathcal{G}_i^{(n)} = |G^{(n,i)}| \sum_{p=1}^N |G^{(n,p)}|.$$

Ainsi, $B(x) - A(x)$ est symétrique. Montrons qu'elle est en plus SDP.

$\forall X \in \mathbb{R}^N$:

$$X^T A(x) X = \underbrace{\sum_{m=1}^M \left(\sum_{i=1}^N H^{(m,i)} X_i \right)^2}_{\text{Terme 1}} + \lambda \underbrace{\sum_{n=1}^{2N} \frac{\psi'([Gx]^{(n)})}{[Gx]^{(n)}} \left(\sum_{i=1}^N G^{(n,i)} X_i \right)^2}_{\text{Terme 2}}$$

Majoration du terme 1 : $\forall m \in \{1, \dots, M\}$:

$$\left(\sum_{i=1}^N H^{(m,i)} X_i \right)^2 \leq \sum_{i=1}^N \sum_{p=1}^N |H^{(m,i)}| |H^{(m,p)}| |X_i| |X_p|.$$

Nous pouvons alors majorer les termes croisés par l'inégalité arithmético-géométrique :

$$|X_i| |X_p| \leq \frac{X_i^2 + X_p^2}{2}$$

$$\left(\sum_{i=1}^N H^{(m,i)} X_i \right)^2 \leq \sum_{i=1}^N \sum_{p=1}^N |H^{(m,i)}| |H^{(m,p)}| \frac{X_i^2 + X_p^2}{2} = \sum_{i=1}^N X_i^2 |H^{(m,i)}| \sum_{p=1}^N |H^{(m,p)}|.$$

Ainsi, on a :

$$\text{Terme 1} \leq \sum_{i=1}^N X_i^2 \sum_{m=1}^M |H^{(m,i)}| \sum_{p=1}^N |H^{(m,p)}| = \sum_{i=1}^N X_i^2 (\mathcal{H}_i^T \mathbf{1}).$$

Majoration du terme 2 : De même que pour le terme 1, on a $\forall n \in \{1, \dots, 2N\}$:

$$\left(\sum_{i=1}^N G^{(n,i)} X_i \right)^2 \leq \sum_{i=1}^N X_i^2 |G^{(n,i)}| \sum_{p=1}^N |G^{(n,p)}|.$$

En multipliant par $\frac{\lambda \psi'([Gx]^{(n)})}{[Gx]^{(n)}} \geq 0$ et en sommant sur n :

$$\text{Terme 2} \leq \lambda \sum_{i=1}^N X_i^2 \sum_{n=1}^{2N} |G^{(n,i)}| \sum_{p=1}^N |G^{(n,p)}| \frac{\psi'([Gx]^{(n)})}{[Gx]^{(n)}} = \lambda \sum_{i=1}^N X_i^2 \left(\mathcal{G}_i^T \frac{\psi'(Gx)}{Gx} \right).$$

On obtient finalement :

$$X^T A(x) X \leq \sum_{i=1}^N X_i^2 \left(\mathcal{H}_i^T \mathbf{1} + \lambda \mathcal{G}_i^T \frac{\psi'(Gx)}{Gx} \right) = \sum_{i=1}^N b_i(x) X_i^2 = X^T B(x) X.$$

$$\Longleftrightarrow$$

$$X^T (B(x) - A(x)) X \geq 0.$$

$B(x) - A(x)$ est donc bien symétrique semi-définie positive.

3.5.2 parallel MM quadratic algorithm

$B \geq A$ et B est diagonale, symétrique définie positive. On peut donc appliquer l'algorithme parallèle de MM car la norme B est plus grande que la norme A . En effet, la majoration que l'on avait trouvée à la question 3.2.1 est aussi majorable en utilisant la norme B . Cela justifie l'utilisation de l'algorithme MM parallèle avec B (qui est beaucoup plus simple à calculer car B est facile à inverser)